Comparando desempenho de threads Java aplicadas ao servidor Tomcat

Felipe Rosa, Walter Silvestre Coan

Bacharelado em Engenharia de Sofware
Universidade da Região de Joinville (Univille) Joinville – SC – Brasil

feliperosa.1@univille.br, walter.s@univille.br

Resumo. *Dada a relevância da linguagem Java na computação e a nova forma de execução com threads virtuais, este trabalho apresenta uma análise comparativa feita através da execução de um experimento com três cenários (cada um utilizando uma implementação de thread diferente da linguagem Java) aplicadas ao servidor Tomcat. Nos cenários, é utilizada uma ferramenta para disparo de requisições HTTP para o servidor, obtendo dados como percentual de sucesso das requisições e latência da resposta. Adicionalmente, enquanto as requisições são executadas, uma ferramenta de análise de memória, consumo de CPU e threads do SO é utilizada para extrair esses dados da aplicação. Com base no experimento, verificou-se que nos cenários em que as threads virtuais foram utilizads, houve*

Abstract. *Given the relevance of the Java language in computing and the new way of executing with virtual threads, this work presents a comparative analysis made through the execution of an experiment with four scenarios (each one using a thread implementation of the Java language) applied to the Tomcat server. In the scenarios, a tool is used to trigger HTTP requests to the server, obtaining data such as the percentage of success of the requests and latency of the response. Additionally, while the requests are being executed, a tool for analyzing memory, CPU consumption and OS threads is used to extract this data from the application. Based on the experiment data, it was verified that in the scenarios in which the virtual threads were used, there was less use of RAM memory and lower latency when compared to the other forms.*

1. Introdução

Com a popularização dos multiprocessadores, as linguagens de programação têm fornecido mecanismos alternativos para implementar concorrência, visando melhor experiência de desenvolvimento e aproveitamento de recursos dos dispositivos. Nesse contexto, a linguagem de programação Java introduziu uma nova forma de utilização de *threads*, aplicadas neste trabalho ao servidor Tomcat e sendo comparada às demais implementações já existentes.

A linguagem de programação Java é constantemente elencada entre as mais populares da computação (TIOBE Index, 2023), o que se justifica por motivos como:

neutralidade de arquitetura, portabilidade e robustez (SCHILDT, 2015). Em aplicações desenvolvidas em Java para o mundo web, o servidor de aplicação Tomcat é o mais utilizado (JREBEL, 2022), reconhecido por ser uma opção de livre utilização (*open source*), leve e com amplo suporte da comunidade de software.

Portanto, dada a ampla utilização da linguagem Java e do servidor Tomcat em aplicações, este trabalho tem como objetivo comparar os indicadores de execução de uma aplicação utilizando *threads* virtuais e demais abordagens existentes, visando responder à seguinte questão de pesquisa: quais as diferenças de desempenho entre as implementações de *threads* em Java, quando aplicadas ao servidor Tomcat?

2. Revisão da literatura

2.1 Sistemas operacionais e multiprogramação

Para Tanenbaum (2016), os sistemas operacionais (SOs) surgiram principalmente para gerenciar complexidade de hardware, sendo essencial que ele otimize os recursos disponíveis. Silberschatz (2016) destaca que um dos aspectos de um SO moderno é a capacidade de multiprogramação, ou seja, de poder executar diferentes tarefas e garantir que o processamento da CPU seja compartilhado entre elas. Para isso, é essencial que as tarefas estejam definidas de forma padronizada, papel de processos e threads.

2.2 Processos e *threads*

Um processo pode ser definido como um programa carregado na memória principal e em execução pelo computador (SILBERSCHATZ, 2016), contendo recursos associados a ele. Apesar de agregar informações, a abstração que executará na Unidade Central de Processamento (CPU) é a nível de *thread*.

Silberschatz (2016) define *threads* como unidades básicas de utilização da CPU, sendo essencialmente úteis quando se deseja executar mais de um procedimento dentro de um mesmo processo. Tanenbaum (2016) destaca alguns motivos para utilização de *threads*: em aplicações com muitas atividades ao mesmo tempo e com bloqueios, por bloquear apenas a *thread* e não a aplicação como um todo; por serem mais fáceis de criar e destruir quando comparado aos processos; e por serem especialmente úteis em sistemas com múltiplas CPUs.

2.3 A JVM e modelos de m*ultithreading* em Java

Java é executada a partir da máquina virtual da linguagem (JVM) no sistema operacional em que foi instalada (SILBERSCHATZ, 2016). Ao compilar um código Java, são gerados binários intermediários (*bytecode*) que são carregados pela JVM e interpretados em tempo de execução para as instruções do hardware.

Para possibilitar o desenvolvimento de aplicações com mais de uma unidade de execução (*multithreading*), a linguagem Java (SILBERSCHATZ, 2016) disponibiliza algumas classes utilitárias, destacando-se: (1) através da instância da classe *Thread*, que cria a *thread* na JVM (*Java Virtual Machine*, ambiente de execução da linguagem) e no sistema operacional, sendo descartada após o fim da execução; e através de "*Executors"*, que oferecem uma interface com diferentes formas de criar e gerenciar *threads*, voltadas para submissão de tarefas (BLOCH, 2018).

Neste trabalho, *multithreading* é implementado apenas a partir da interface "*Executor*", sendo utilizados: "*Executor*" de banco de threads ("*thread pools*") em cache (*threads* criadas conforme demanda e reaproveitadas entre as tarefas submetidas) e "*Executor*" de threads de tipo virtual, por tarefa (que utiliza o novo conceito de *threads* virtuais para as execuções).

2.4 Tipos de *thread* em Java

A linguagem Java tradicionalmente utiliza o modelo de *multithreading* "um para um", em que para cada thread criada dentro da JVM, outra deve ser criada no SO hospedeiro, estabelecendo relacionamento único e direto, conforme ilustrado na figura 1.

Figura 1: Modelo de *multithreading* um para um.

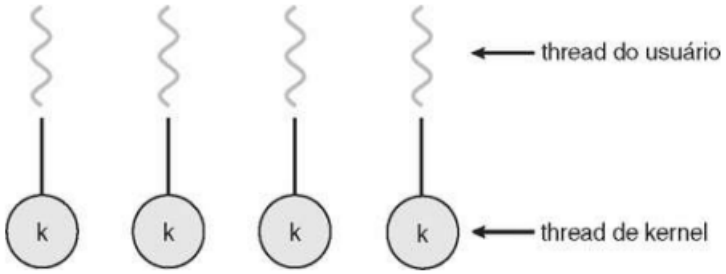

Fonte: Silberschatz et al. (2016, p. 120).

Apesar de facilitar concorrência devido a relação direta com *threads* do SO, pode ocorrer redução no desempenho da aplicação quando criadas muitas threads, devido restrições do SO e riscos de esgotamento de recursos (SILBERSCHATZ, 2016).

A nova proposta com threads virtuais implementada na JEP 444 (forma de inserir mudanças no ambiente de execução da linguagem Java) é de que o código de uma thread Java continue sendo executado em uma thread do sistema operacional, mas que não seja exclusiva de uma única thread da JVM, mas utilizada por várias delas (PRESSLER, 2022). Neste modelo, uma thread virtual pode ser executada em diferentes threads do sistema operacional, ocorrendo uma troca sempre que houver alguma operação que bloqueie ou que esteja esperando por resultado que não seja de processamento na CPU, conforme ilustrado na figura 2.

Figura 2: Relação de uma thread comum e de uma thread virtual executando na thread do SO.

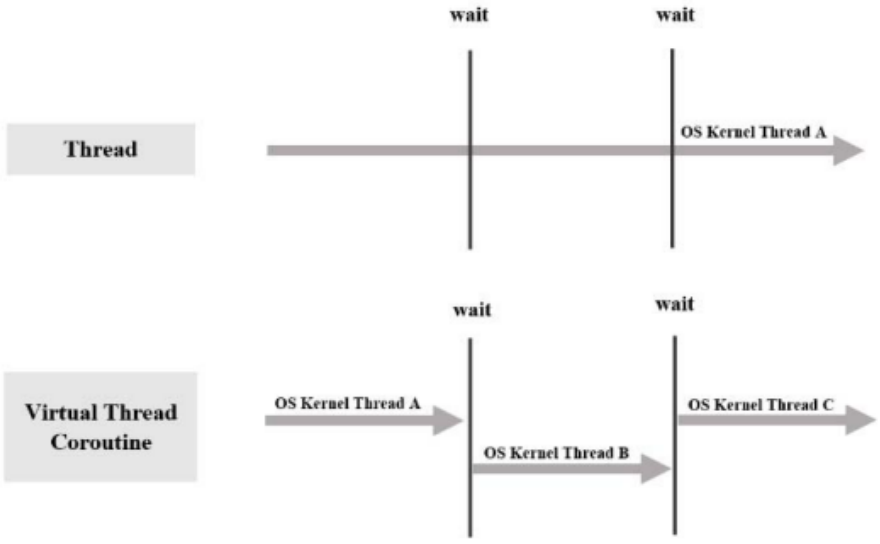

Fonte: Beronić et al. (2022, p. 1468).

O modelo de *threads* virtuais traz alguns benefícios (GOETZ, 2022), como: as informações são armazenadas no espaço de memória gerenciado pela JVM, não mais aguardando alocação do SO; são mais fáceis de criar e destruir por não necessitar aguardar a criação de recursos no SO hospedeiro; utilizam as mesmas APIs (classes utilitárias) do modelo tradicional e por possibilitar manter o estilo de programação síncrono (em contrapartida ao modelo assíncrono/reativo).

A partir dessa proposta, são introduzidos novos conceitos (PRESSLER, 2022): *platform threads* (modelo tradicional de threads, uma thread da JVM é vinculada a uma

thread do SO), *virtual threads* (thread que é criada e gerenciada pela JVM, mas sempre que precisar ser executada na CPU, é executada na thread do sistema operacional) e *carrier thread*s (são threads criadas pela JVM no SO para executar tarefas das *virtual threads*).

2.5 Servidor Tomcat

Tomcat é um servidor de aplicações de código aberto construído em Java que possibilita, dentre outras funcionalidades, criar aplicações web que são executadas quando alguma URL mapeada for recebida através de uma requisição HTTP.

Segundo documentação do Apache Tomcat, internamente as requisições são recebidas através do componente *Connector*, que escuta na porta TCP configurada e extrai as informações contidas na requisição. Estas informações são recebidas pelo componente *Engine*, que as repassa para a *servlet* (aplicação Java) correspondente, onde são definitivamente processadas. Após ser tratada em uma das threads do componente *Executor*, a requisição é finalizada e a *thread* utilizada no processamento é devolvida para ser reutilizada.

Através de arquivos de configuração é possível customizar características dos componentes mencionados. Por exemplo: por padrão, o componente *Executor*, mencionado anteriormente, é configurado contendo apenas duzentas *threads* de plataforma para processar todas as requisições recebidas, podendo ser modificado para outro modelo ou quantidade de *threads*, mudança esta que ocorre neste trabalho.

2.6 Trabalhos relacionados

Apesar das threads virtuais terem sido recentemente disponibilizadas em Java (2021), alguns pesquisadores já realizaram experimentos comparando com as demais formas existentes. Em um teste (Beronić et al, 2021) foram executados algoritmos de ordenação e comparadas métricas como velocidade de criação de *threads* e de execução. Nos resultados coletados, observou-se que: o tempo para criar um milhão de threads comuns (*platform threads*) foi 2,23 vezes mais lento que a criação do mesmo número de *threads* virtuais. Quanto a execução, no algoritmo de *Merge Sort* em um *array* com 64000 elementos, observou-se que com *threads* virtuais a ordenação foi 30,82% mais rápida do que utilizando *threads* de plataforma.

Em outro trabalho (Beronić et al, 2022), os pesquisadores fizeram comparações com: threads de plataforma e virtuais das linguagens Java e Kotlin. A comparação faz sentido visto que a linguagem Kotlin utiliza o mesmo ambiente de execução (JVM). Diferente do artigo anterior, o teste continha um servidor web que recebia as requisições e dentre as métricas colhidas, a latência observada apresentou diferença, sempre em favorecimento às *threads* virtuais, conforme figura 3.

Figura 3: Latência média de resposta às requisições utilizando diferentes formas de threads.

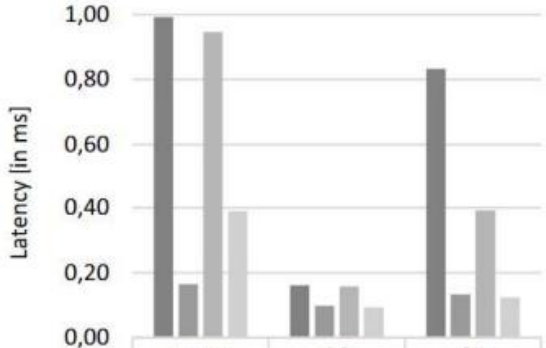

	mean	50	95
Java - threads	0,9921	0,1615	0,8331
Java - virtual threads	0,1642	0,0988	0,1329
Kotlin - threads	0,9464	0,1582	0,3915
Kotlin - coroutines	0,3896	0,0931	0,1234

Fonte: Beronić et al. (2022, p. 1470).

Em ambos os testes mencionados, os pesquisadores não compararam outras métricas, como consumo de memória ou fizeram testes utilizando outras soluções de *multithreading* em Java, como através dos "*Executors*".

3. Procedimentos metodológicos

Este trabalho faz uma análise comparativa a partir da execução de três cenários de teste: dois cenários substituindo o componente *Executor* do servidor Tomcat com tipos distintos de *threads* Java, e um cenário utilizando o componente *Executor* padrão.

Nos experimentos foi utilizado um ambiente de testes com as seguintes características: computador com sistema operacional Linux Ubuntu versão 22.04 LTS em um hardware de 8GB de memória RAM e processador Intel(R) Core (TM) i7, composto de 8 núcleos virtuais de processamento. Além disso, foram utilizados:

linguagem Java na versão prévia OpenJDK 21 contendo as *threads* virtuais; a ferramenta VisualVM na versão 2.1.6 para extrair os indicadores de consumo de recursos computacionais (*profiling*); a ferramenta Vegeta na versão 7.0.0 para disparo de requisições HTTP; e o servidor Tomcat na versão 11.0.0 como servidor de aplicação, ambos sendo executados no mesmo hardware. O experimento foi conduzido em uma estrutura de cliente/servidor, conforme ilustrado na figura 4.

Figura 4: Fluxograma de execução dos testes.

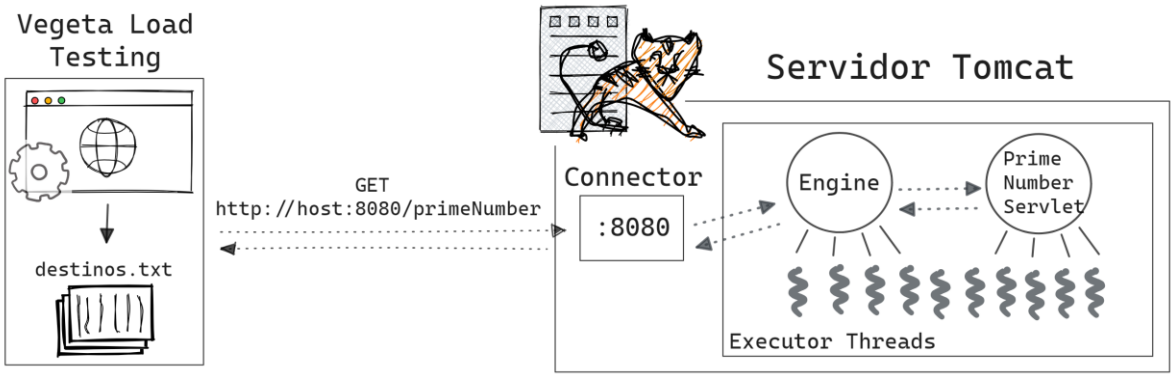

Fonte: elaborado pelo autor.

O cliente (ferramenta Vegeta) lê o arquivo texto contendo as URLs de destino e realiza o disparo de 5000 requisições HTTP por segundo, durante 10 segundos seguidos. O servidor Tomcat contém a aplicação Java (*servlet*) PrimeNumberServlet, que é chamada para processar todas as requisições HTTP de tipo GET que correspondam a URL "/primeNumber" mapeada.

Internamente, o servidor Tomcat é composto de um *Connector* que escuta a porta 8080 da máquina e redireciona as requisições para o componente *Engine* sempre que receber uma requisição HTTP. Neste componente é identificada a *servlet* responsável pela requisição (a partir das URLs mapeadas) e feita a chamada do método da *servlet* para definitivamente processá-la. Ambos (*Engine* e PrimeNumberServlet) utilizam *threads* "Executor" disponíveis para realizar o processamento necessário para responder a requisição.

Na URL de cada requisição disparada pela ferramenta Vegeta existe um número aleatório que é lido pela *servlet* e o parâmetro "delayDuration", onde é informado o tempo que a *thread* de execução será suspensa (instrução "*sleep()*"), em milissegundos. Nas requisições disparadas, os números utilizados foram gerados de forma aleatória

com a linguagem Java, tendo valor entre 100.000 e 1.000.000 e no parâmetro que suspende a execução da thread, o valor de 100ms.

O método da *servlet* que processa a requisição executa um algoritmo na thread do *Executor* contendo os seguintes passos: (1) ler a URL recebida pelo servidor e identificar o número inteiro informado; (2) criar um objeto na memória; (3) fazer a chamada do método que verifica se o número é primo; (4) fazer a chamada de método estático responsável por escrever em arquivo ".CSV" as informações da requisição processada; (5) suspender a requisição no tempo informado na URL; (6) e escrever o retorno no objeto de resposta da requisição, contendo o resultado se o número era primo ou não, e a *string* que foi gravada no arquivo ".CSV".

Nas etapas 4 e 5, o processamento da requisição é bloqueado, ou seja, enquanto não houver retorno, a *thread* fica aguardando o resultado da chamada executada. Estas interrupções têm por motivação simular uma situação que é recorrente em aplicações web, quando por exemplo é feita uma conexão no banco de dados e a thread de execução permanece aguardando o retorno da conexão realizada.

Para cada requisição recebida no servidor Tomcat, os passos descritos acima são executados. A diferença entre cada cenário está no tipo de *thread* que irá processar a requisição e sofrer as interrupções do algoritmo, sendo: Cenário 1 (com threads virtuais), Cenário 2 (com banco de threads de plataforma em cache), Cenário 3 (com threads do servidor Tomcat).

Para utilizar os diferentes modelos, antes do servidor Tomcat ser inicializado, o arquivo "server.xml" do diretório de configurações é substituído pelo arquivo contendo o modelo de *threads* a ser testado. Nos três cenários, a *tag* do arquivo XML que configura o componente *Connector* é alterada, visando manter a uniformidade dos testes (ambos recebem os parâmetros "maxConnections=100000" e "maxThreads="100000", para evitar que o limite de requisições e threads em utilização interfira nos testes).

Para coleta de dados do lado do cliente, após a ferramenta de disparo obter a resposta de todas as 50.000 requisições executadas (5000/segundo), é feito o cálculo do tempo médio de resposta das requisições (latência). Do servidor, a ferramenta VisualVM coleta dados do processo do servidor Tomcat no SO, extraindo a cada segundo informações de: memória utilizada e reservada pela JVM na memória RAM

(em bytes), percentual de uso de CPU e número de threads do sistema operacional em uso pelo processo. Ao fim da execução é exportado o arquivo ".CSV" contendo todas as informações coletadas.

Para executar o experimento com cada tipo de *thread*, um *script* Bash Linux foi criado com as etapas: trocar o arquivo de configuração do servidor Tomcat (server.xml) contendo as informações do tipo de thread; iniciar o servidor, executar o disparo de requisições (5000 requisições/segundo, durante 10 segundos seguidos) sete vezes, processo feito para os três cenários.

4. Análise dos dados e discussão dos resultados

Para visualização das informações, gráficos foram gerados com a biblioteca MatplotLib da linguagem Python, com base nos dados gerados pelas ferramentas VisualVM e Vegeta. Dos sete disparos de requisições realizados, os dados gerados pelas duas primeiras execuções são desconsiderados para descartar os efeitos da compilação *just-in-time* e do carregamento de classes da JVM.

Dos dados gerados pelo cliente (Vegeta), todas as requisições obtiveram retorno (código HTTP 200). No gráfico da figura 5 se observa pouca variação na latência (média de tempo de resposta das 50.000 requisições) em cada execução por tipo de thread, mas na média, as execuções com *threads* virtuais apresentaram melhor performance.

Figura 5: Latência média das requisições disparadas, para cada execução.

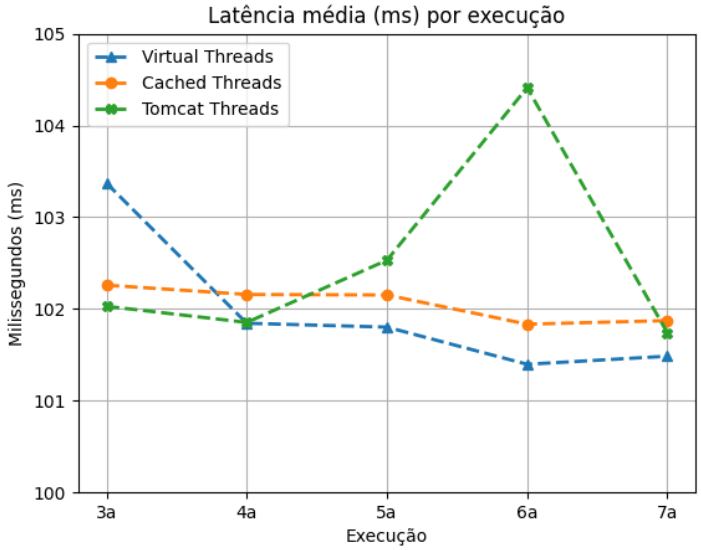

Fonte: elaborado pelo autor.

Quanto aos indicadores do servidor: na figura 6 é representado o pico de consumo de memória pelo servidor Tomcat por tipo de *thread* em cada execução, onde observa-se que o modelo tradicional de *threads* do Tomcat manteve baixo consumo de memória, enquanto as *threads* virtuais demandaram mais memória.

Figura 6: Pico de consumo de memória por tipo de *thread*, em cada execução.

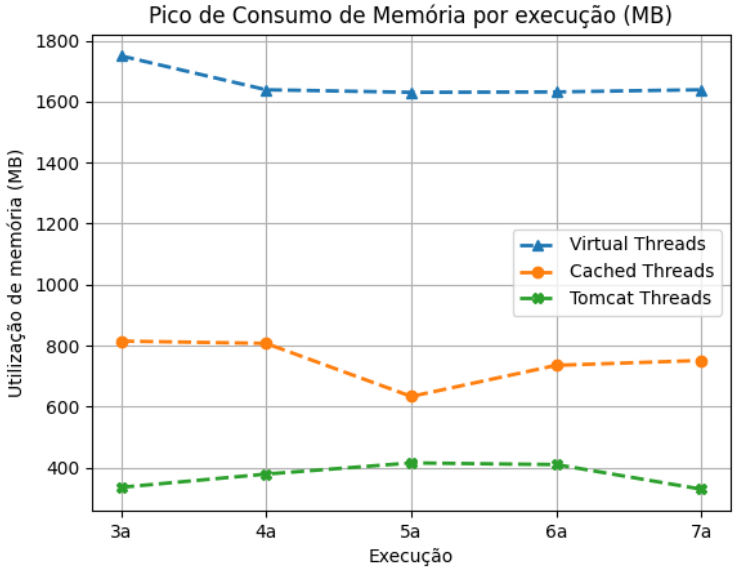

Fonte: elaborado pelo autor.

Quanto ao uso de CPU do dispositivo pelo servidor Tomcat, não se observou variação expressiva entre os modelos de *thread*, conforme ilustrado na figura 7.

Figura 7: Pico de consumo de CPU por tipo de *thread*, em cada execução.

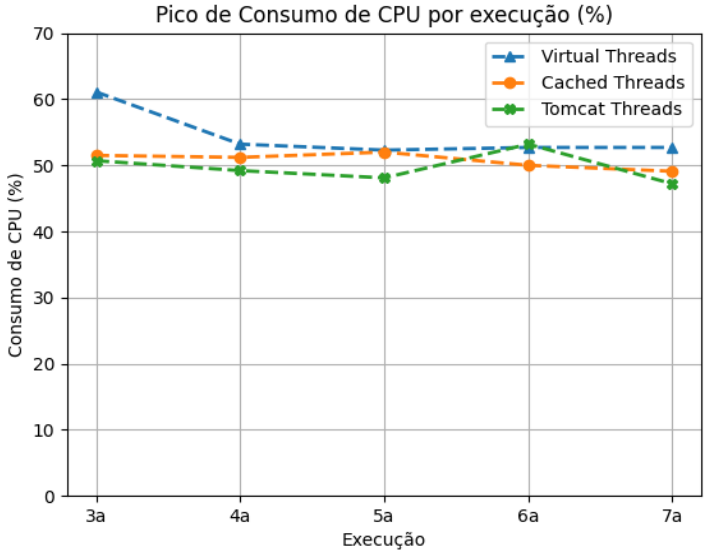

Fonte: elaborado pelo autor.

Já na utilização de *threads* do sistema operacional pelo processo do servidor Tomcat, as execuções com *threads* virtuais utilizaram um número expressivamente menor quando comparado aos demais modelos de *threads*, conforme figura 8.

Figura 8: Pico de uso de *threads* do SO por modelo de threads da JVM, em cada execução.

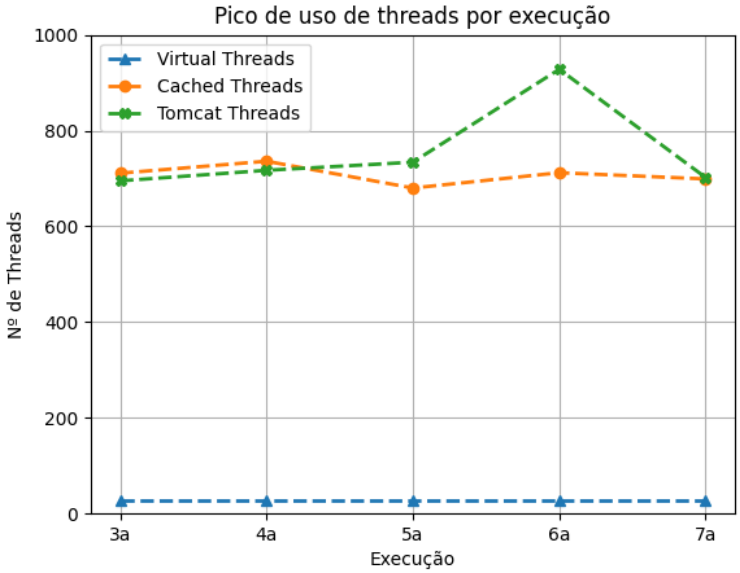

Fonte: elaborado pelo autor.

5. Conclusão

Desde que a linguagem Java decidiu implementar as *threads* virtuais em seu ambiente de execução, inúmeras questões surgiram sobre o novo modelo: se traria mais eficiência, se substituiria todas as demais implementações de *threads* em uso ou ainda, se teria adoção pelos desenvolvedores nas aplicações e ferramentas construídas, questões essas ainda não respondidas totalmente.

O obtivo deste trabalho foi aplicar as *threads* virtuais no servidor Tomcat, amplamente utilizado, e experimentar se traria melhorias significativas na ferramenta quando comparada às demais formas já existentes e ao padrão utilizado pelo servidor. O experimento utilizou o modelo cliente-servidor, onde o cliente realiza um teste de carga com disparo de 50.000 requisições em 10 segundos.

Com o apoio da ferramenta de disparo de requisições, verificou-se uma variação muito pequena na latência média de resposta em cada um dos modelos. Nos dados do

servidor, o uso de CPU em cada implementação também teve pouca variação. Já no consumo de memória, as *threads* virtuais chegaram a utilizar 5,2 vezes mais memória do que o modelo tradicional de *threads* do Tomcat em uma das execuções. Em contraste, o modelo de *threads* virtuais manteve baixa utilização de *threads* do SO (pico de 27 *threads*) em uso pelo processo do servidor, enquanto que a execução com as threads tradicionais do servidor Tomcat foi a que demandou maior número (pico de 928 *threads*).

Apesar de na versão 10 do servidor Tomcat terem sido efetuadas alterações para possibilitar o uso de *threads* virtuais, com base no cenário executado em cada um dos casos de teste, verificou-se que as *threads* virtuais não trouxeram melhoras expressivas quando utilizadas no componente *Executor* do servidor Tomcat e comparadas ao modelo de *threads* em cache e ao já utilizado pelo servidor, seja por limitações do servidor Tomcat ou pela sobrecarga de gerenciamento das threads virtuais, que pode ter impactado negativamente o desempenho geral e gerado um ganho limitado ou até diminuído a eficiência.

Este estudo buscou contribuir no entendimento da aplicabilidade das *threads* virtuais em ferramentas com ampla utilização do mundo Java, como o servidor Tomcat, em contraste de outras implementações já existentes. Como a versão da linguagem com *threads* virtuais ainda está em desenvolvimento, é possível que melhoras sejam implementadas e a aplicação nas ferramentas tenha melhor resultado.

Para trabalhos futuros, abordagens executando novos cenários de teste com outras configurações do servidor Tomcat; utilizando uma versão atualizada com suporte de threads virtuais em outros componentes do servidor ou ainda com a versão da linguagem Java com suporte de longo prazo (LTS) contendo as threads virtuais, podem ser úteis para esclarecimento das vantagens e limitações do novo modelo e das demais abordagens.

Referências

BERONIĆ, D.; PUFEK, B.; MIHALJEVIĆ, B.; RADOVAN, A. **On Analyzing Virtual Threads – a Structured Concurrency Model for Scalable Applications on the JVMs**, MIPRO 2021. 01 out 2021.

BERONIĆ, D.; MODRIĆ, L.; MIHALJEVIĆ, B.; RADOVAN, **A. Comparison of Structured Concurrency Constructs in Java and Kotlin – Virtual Threads and Coroutines**, MIPRO 2022. 23 maio 2022.

BLOCH, Joshua. **Effective Java: Best practices for**. 3ª edição. Pearson Education Inc., 2018.

GOETZ, Brian. **Java Concurrency in Practice**. 1ª edição. Addison-Wesley 2006.

GOETZ, Brian. **Virtual Threads: New Foundations for High-Scale Java Applications**. Disponível em: https://www.infoq.com/articles/java-virtual-threads/. Acesso em 25 jun. 2023.

GOMES, Francisco M. **Pré-cálculo: Operações, equações, funções e trigonometria**. Disponível em: Minha Biblioteca, Cengage Learning Brasil, 2018.

HORSTMANN, Cay. **Conceitos de Computação com Java**. Grupo A, 2009. E-book. ISBN 9788577804078. Disponível em: Biblioteca Digital.

HORSTMANN, Cay. **Core Java Volume I: Fundamentals**. 12ª edilçao. Pearson Education Inc., 2021.

JREBEL. **JREBEL 2022 Java Developer Productivity Report**. Disponível em: https://www.jrebel.com/resources/java-developer-productivity-report-2022. Acesso em 25 jun. 2023.

Matplotlib. **Matplotlib: Visualization with Python**. Disponível em: https://matplotlib.org/. Acesso em 25 jun. 2023.

PRESSLER, Ron; BATEMAN, Alan. **JEP 425: Virtual Threads (Preview)**. Disponível em: https://openjdk.org/jeps/425. Acesso em 25 jun. 2023.

PRESSLER, Ron; BATEMAN, Alan. **JEP 444: Virtual Threads**. Disponível em: https://openjdk.org/jeps/425. Acesso em 25 jun. 2023.

SCHILDT, Herbert. **Java para iniciantes**. 6ª edição. Oracle Press, 2015.

SILBERSCHATZ, Abraham; GALVIN, Peter B.; GAGNE, Greg. **Sistemas Operacionais com Java**. 8ª edição. Elsevier Editora, 2016.

TANENBAUM, Andrew S. **Sistemas Operacionais Modernos**. 4ª edição. Pearson, 2016.

TIOBE INDEX. **TIOBE Index for October 2023**. Disponível em: https://www.tiobe.com/tiobe-index/. Acesso em 25 jun. 2023.

VEGETA. **Vegeta: HTTP load testing tool and library**. Disponível em: https://github.com/tsenart/vegeta/. Acesso em 25 jun. 2023.

VISUALVM. **VisualVM: All-in-one Java troubleshooting Tool**. Disponível em: https://visualvm.github.io/. Acesso em 25 jun. 2023.